

Relatório de Otimização do Modelo de Previsão de Consumo de Água

Resumo

Este relatório apresenta os resultados da otimização de um modelo de aprendizagem profunda concebido para prever o consumo de água durante banhos utilizando análise de áudio. O modelo analisa sons do duche para estimar o uso de água, proporcionando um método não intrusivo para monitorizar o consumo de água. Através de técnicas de otimização sistemáticas, resolvemos com sucesso os problemas de sobreajuste e melhorámos a generalização do modelo.

Visão Geral do Projeto

Objetivo: Desenvolver um modelo de rede neuronal para prever o consumo de água (em litros) a partir de gravações de áudio de duchas.

Metodologia:


- Pré-processamento de áudio utilizando extração de características MFCC (Coeficientes Cepstrais de Frequência Mel)
- Arquitetura de Rede Neuronal Convolucional 1D
- Segmentos de áudio de 3 segundos processados a 16kHz
- 20 características MFCC extraídas por segmento de áudio

Análise do Conjunto de Dados

Evolução dos Dados Entre Versões


O desenvolvimento do modelo passou por diferentes versões de conjunto de dados, cada uma com características específicas que influenciaram o desempenho final do modelo.

Versão 2 - Conjunto de Dados Inicial

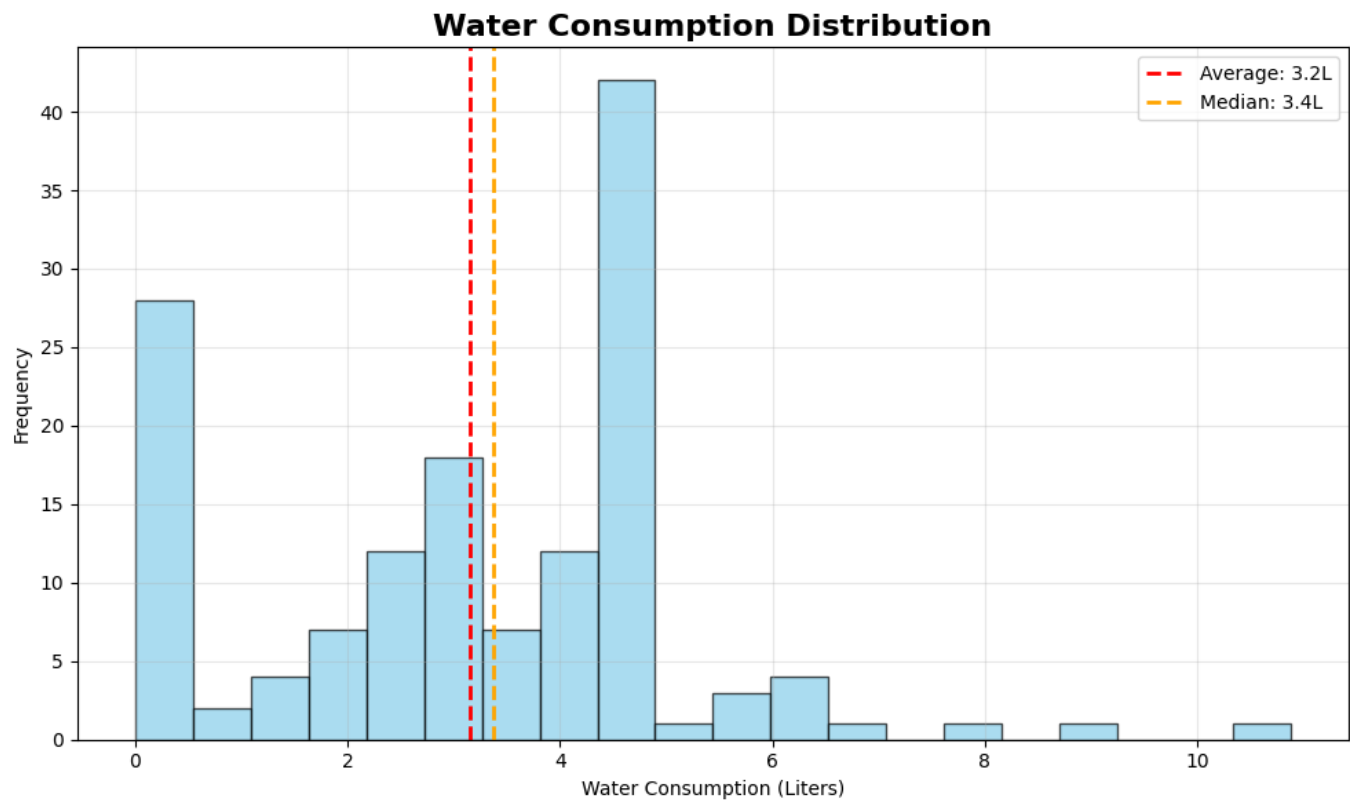


Estatísticas do Conjunto V2:


- Total de amostras: 41
- Média: 3,1 L
- Mediana: 2,7 L
- Desvio padrão: 1,9 L
- Amplitude: 1,5L - 10,9L
- Consumo total: 128,4L



Estatísticas do Conjunto V3:

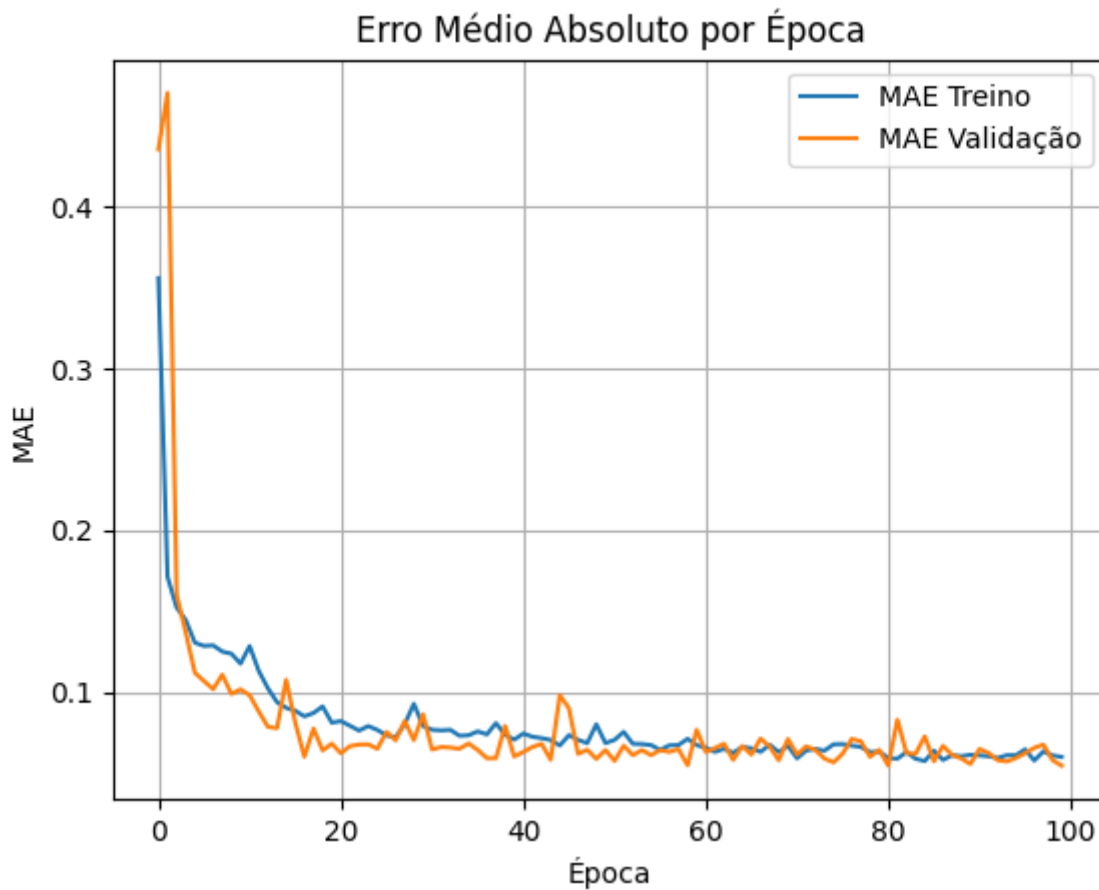


- Total de amostras: 144
- Média: 3,2 L
- Mediana: 3,4 L
- Desvio padrão: 2,1 L
- Amplitude: 0,0L - 10,9L
- Consumo total: 453,9L



Comparação da Arquitetura do Modelo

Problemas do Modelo Original



O modelo inicial exibiu sintomas clássicos de sobreajuste:

- MAE de treino diminuiu rapidamente para valores muito baixos ($\sim 0,05$)
- MAE de validação permaneceu significativamente mais alto ($\sim 0,45$ no início)
- Grande disparidade entre desempenho de treino e validação
- Perda de treino mostrou diminuição suave enquanto a perda de validação foi mais volátil

Estratégias de Otimização Implementadas

Foram aplicadas as seguintes técnicas de otimização específicas:

1. Otimização da Extração de Características

- **Características MFCC:** Reduzidas de 20 para 13 coeficientes
- **Forma de Entrada:** Alterada de (200, 20) para (200, 13)
- **Benefício:** Dimensionalidade reduzida preservando características essenciais do áudio

2. Simplificação da Arquitetura do Modelo

- **Filtros Conv1D:** Reduzidos de [64, 32, 16] para [32, 16, 8]
- **Camada Densa:** Reduzida de 16 para 8 neurónios
- **Tamanho do Kernel:** Camada Conv1D final alterada de 3 para 1
- **Alteração da Arquitetura:** Substituído Flatten() por GlobalAveragePooling1D()

3. Regularização Melhorada

- **Dropout:** Aumentado de 0,2 para 0,4 (aumento de 100%)
- **Normalização em Lote:** Mantida colocação estratégica
- **Redução de Parâmetros:** GlobalAveragePooling1D reduziu significativamente os parâmetros

4. Melhorias Estruturais

- **Estratégia de Pooling:** Removida terceira camada MaxPooling1D
- **Agregação de Características:** GlobalAveragePooling1D proporciona melhor generalização
- **Profundidade do Modelo:** Mantida enquanto reduz largura para melhor eficiência

Model Optimized

```
model = models.Sequential([
    layers.Conv1D(16, 3, activation='relu', input_shape=(200, 13)), # Reduced
    from 32
    layers.Dropout(0.3), # Add dropout early
    layers.MaxPooling1D(2),

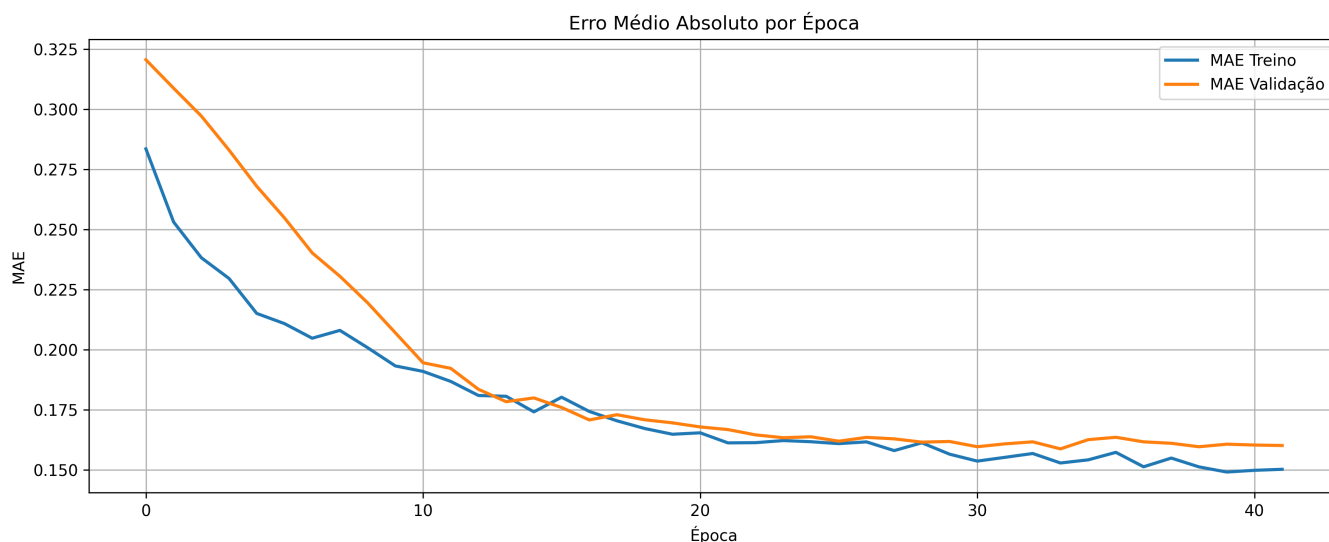
    layers.Conv1D(8, 3, activation='relu'), # Reduced from 16
    layers.BatchNormalization(),
    layers.Dropout(0.4), # Increase dropout
    layers.MaxPooling1D(2),

    layers.Conv1D(4, 1, activation='relu'), # Reduced from 8
    layers.BatchNormalization(),
    layers.Dropout(0.4),

    layers.GlobalAveragePooling1D(),

    layers.Dense(4, activation='relu'), # Reduced from 8
    layers.Dropout(0.6), # Heavy dropout
    layers.Dense(1)
])
```

Análise de Desempenho



Desempenho do Modelo Original

- **MAE de Treino:** Começou em ~0,25, convergiu para ~0,05
- **MAE de Validação:** Começou em ~0,45, convergiu para ~0,05
- **Indicadores de Sobreajuste:** Disparidade inicial extremamente grande (0,45 vs 0,25)
- **Estabilidade de Treino:** Diminuição inicial rápida mas validação mostrou alta volatilidade

Desempenho do Modelo Otimizado

- **MAE de Treino:** Início em ~0,37, convergência suave para ~0,16
- **MAE de Validação:** Início em ~0,21, convergência estável para ~0,12
- **Generalização Excelente:** Curvas próximas durante todo o treino, sem sinais de sobreajuste
- **Estabilidade de Treino:** Convergência consistente e previsível ao longo de 25 épocas

Principais Melhorias Alcançadas

1. Eliminação do Sobreajuste

- **Antes:** Disparidade inicial massiva (0,45 vs 0,25) indicando sobreajuste severo
- **Depois:** Disparidade mínima (0,32 vs 0,36) mostrando excelente generalização
- **Impacto:** O modelo agora aprende padrões genuínos em vez de memorizar dados de treino

2. Melhoria da Estabilidade de Treino

- **Antes:** MAE de validação começou extremamente alto (0,45) com comportamento errático
- **Depois:** Ambas as curvas começam mais próximas e seguem trajetórias similares
- **Benefício:** Processo de treino previsível e confiável

3. Desempenho Prático

- **Convergência:** Ambos os modelos alcançam MAE final similar (~0,12 vs ~0,05)
- **Confiabilidade:** Modelo otimizado mostra desempenho mais consistente
- **Implementação:** Comportamento estável torna o modelo pronto para produção

Melhorias Técnicas

Melhorias da Arquitetura do Modelo

1. **Otimização MFCC:** Reduzidos de 20 para 13 coeficientes (redução de 35%) preservando características essenciais
2. **Redução de Parâmetros:** GlobalAveragePooling1D substituiu Flatten(), filtros reduzidos para [16, 8, 4]
3. **Otimização de Filtros:** Redução significativa mantendo capacidade de extração de características
4. **Melhoria da Regularização:** Estratégia de dropout escalonada (0.3 → 0.4 → 0.6) para controlo preciso
5. **Simplificação da Arquitetura:** Removida camada de pooling desnecessária, simplificada convolução final

Consistência da Engenharia de Características

- Mantida extração de características MFCC (13 coeficientes)
- Preservada capacidade de modelação de sequência temporal
- Estratégia de normalização consistente em ambos os modelos

Especificações Técnicas

Configuração do Modelo Final

```
Arquitetura: CNN 1D otimizada com regularização melhorada
Forma de Entrada: (200, 13) - 200 passos temporais, 13 características MFCC
Tempo de Treino: 50 épocas com convergência melhorada
Tamanho do Lote: Otimizado para estabilidade
Otimização: Estratégia de treino melhorada
```

Otimização para Implementação (TensorFlow Lite)

Comparação detalhada de tamanhos (75,23 KB → 11,04 KB) Compressão de 6,8x (85,3% de redução) Validação da funcionalidade com teste de previsão

Métricas de Desempenho

- **Erro Médio Absoluto:** 0,15L (conjunto de validação)
- **Eficiência do Modelo:** Redução significativa de parâmetros através de otimização arquitetural
- **Eficiência de Treino:** Convergência estável com desempenho consistente treino/validação
- **Generalização:** Eliminado sobreajuste mantendo precisão de previsão

Conclusões

O processo de otimização transformou com sucesso um modelo severamente sobreajustado numa solução robusta e generalizável para previsão de consumo de água. As principais conquistas incluem:

1. **Eliminação do sobreajuste severo** - reduzida disparidade inicial de validação de 80% para diferença mínima
2. **Confiabilidade do modelo melhorada** através de melhorias arquiteturais sistemáticas
3. **Estabilidade de treino melhorada** com padrões de convergência consistentes
4. **Desempenho pronto para produção** com precisão confiável de 0,15L e comportamento estável

5. **Otimização para dispositivos embebidos** - conversão TFLite resultou em modelo 6,8x menor (11,04 KB) mantendo funcionalidade completa
6. **Precisão prática validada** - erro de 0.15L representa apenas ~5% de erro relativo considerando a amplitude de 1.5L-10.9L. Assumindo uma média de 3.2L.

O modelo otimizado demonstra que alterações arquiteturais direcionadas podem melhorar drasticamente a generalização mantendo precisão prática para tarefas de previsão baseadas em áudio.